

AJUSTES DE CURVAS: MÍNIMOS QUADRADOS

Prof. Gabriel Souto

IME/UERJ

2025.2

ROTEIRO DA AULA

- 1 MOTIVAÇÃO
- 2 MÍNIMOS QUADRADOS: CASO DISCRETO
- 3 EXEMPLO - CASO LINEAR
- 4 EXEMPLO - PARÁBOLA
- 5 EXEMPLO - CASO NÃO LINEAR
- 6 EXERCÍCIO

MOTIVAÇÃO

- Na aula anterior, vimos que uma forma de trabalhar com uma função definida por uma tabela de valores é através da **interpolação polinomial**.
- Contudo, a interpolação nem sempre é o método mais adequado, especialmente quando:
 - Deseja-se estimar valores fora do intervalo tabelado (**extrapolação**);
 - Os dados provêm de **experimentos físicos** ou medições, e, portanto, podem conter erros.
- Nesses casos, buscamos uma **função aproximadora** que melhor se ajuste aos dados experimentais, não necessariamente passando por todos os pontos.

MOTIVAÇÃO

- Na aula anterior, vimos que uma forma de trabalhar com uma função definida por uma tabela de valores é através da **interpolação polinomial**.
- Contudo, a interpolação nem sempre é o método mais adequado, especialmente quando:
 - Deseja-se estimar valores fora do intervalo tabelado (**extrapolação**);
 - Os dados provêm de **experimentos físicos** ou medições, e, portanto, podem conter erros.
- Nesses casos, buscamos uma **função aproximadora** que melhor se ajuste aos dados experimentais, não necessariamente passando por todos os pontos.

INTERPOLAÇÃO VS. AJUSTE DE CURVAS

Aspecto	Interpolação Polinomial	Ajuste de Curvas
Objetivo	Passar exatamente por todos os pontos tabelados.	Encontrar uma função que melhor aproxime os pontos, minimizando o erro global.
Erro nos pontos	Erro nulo: $f(x_i) = P(x_i)$.	Erros permitidos: $f(x_i) \approx \phi(x_i)$.
Sensibilidade a ruídos	Alta — qualquer erro experimental distorce o polinômio.	Baixa — tende a suavizar flutuações e ruídos experimentais.
Comportamento fora do intervalo (extrapolação)	Pode oscilar fortemente e gerar valores irreais.	Mais estável e confiável para extrapolações moderadas.
Complexidade	Depende do grau do polinômio ($n - 1$ para n pontos).	Depende da quantidade de funções base escolhidas ($g_1, \dots, g_n$).
Aplicações típicas	Funções conhecidas, tabelas exatas ou sem ruído.	Dados experimentais, medições e observações com incerteza.

QUANDO A INTERPOLAÇÃO NÃO É RECOMENDADA

A interpolação polinomial não é aconselhável quando:

- 1. É preciso obter um valor aproximado da função em algum ponto fora do intervalo tabelado, ou seja, quando há **extrapolação**;
- 2. Os valores tabelados resultam de **experimentos físicos** ou **pesquisas**, que podem conter erros de medida.

PROBLEMA PRÁTICO

Como ajustar uma função $f(x)$ aos dados experimentais de modo que ela:

- se aproxime bem dos valores observados; e
- permita estimar valores em regiões fora da amostra (**extrapolação**)?

ROTEIRO DA AULA

- 1 MOTIVAÇÃO
- 2 MÍNIMOS QUADRADOS: CASO DISCRETO
- 3 EXEMPLO - CASO LINEAR
- 4 EXEMPLO - PARÁBOLA
- 5 EXEMPLO - CASO NÃO LINEAR
- 6 EXERCÍCIO

CASO DISCRETO: PROBLEMA DE AJUSTE

Dados m pontos tabelados (x_i, y_i) , $i = 1, \dots, m$, com $x_i \in [a, b]$.

Objetivo: escolher funções contínuas $g_1(x), g_2(x), \dots, g_n(x)$ e constantes $\alpha_1, \dots, \alpha_n$ tais que

$$\phi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x)$$

se aproxime de $f(x)$ nos pontos amostrados.

MODELO LINEAR (NOS PARÂMETROS)

Chamamos o modelo de **linear** porque os coeficientes α_j aparecem linearmente, ainda que as g_j possam ser *não lineares* em x .

CASO DISCRETO: PROBLEMA DE AJUSTE

Dados m pontos tabelados (x_i, y_i) , $i = 1, \dots, m$, com $x_i \in [a, b]$.

Objetivo: escolher funções contínuas $g_1(x), g_2(x), \dots, g_n(x)$ e constantes $\alpha_1, \dots, \alpha_n$ tais que

$$\phi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x)$$

se aproxime de $f(x)$ nos pontos amostrados.

MODELO LINEAR (NOS PARÂMETROS)

Chamamos o modelo de **linear** porque os coeficientes α_j aparecem linearmente, ainda que as g_j possam ser *não lineares* em x .

ESCOLHA DAS FUNÇÕES-BASES $g_n(x)$

Como escolher $g_1, \dots, g_n$?

- Observando o **diagrama de dispersão** (o gráfico dos pontos).
- Usando fundamentos teóricos do fenômeno (modelo físico, lei empírica).

Exemplos comuns de funções-bases (g_n):

- Polinomial: $a_0 + a_1x + a_2x^2 + \dots + a_nx^n$
- Exponencial: $e^{\beta x}$, $e^{\beta_1 x}$, $e^{\beta_2 x}$
- Potência: x^k , $k \in \mathcal{R}$
- Logarítmica: $\ln x$
- Mistas: $1, x, \ln x$ (quando faz sentido)
- Sazonais: $\text{sen}(kx)$, $\text{cos}(kx)$

ESCOLHA DAS FUNÇÕES-BASES $g_n(x)$: DIAGRAMA DE DISPERSÃO

Antes de ajustar qualquer modelo:

- 1 Dada a tabela de pontos (x_i, y_i) , **plote** os pontos no plano cartesiano.
- 2 O gráfico resultante é o **diagrama de dispersão**.
- 3 A partir dele, **visualize a tendência** (linear? curvilínea? exponencial? sazonal?).
- 4 Só então formule uma **hipótese de modelo** escolhendo as funções-base $g_j(x)$.

Por que fazer isso?

- Evita escolher um modelo incompatível com o comportamento dos dados.
- Ajuda a decidir entre bases *polinomiais*, *exponenciais*, *trigonômicas*, etc.
- Já indica possíveis transformações (centralizar x , usar $\ln x$, etc.).



EXEMPLO 1: TABELA E DISPERSÃO

Seja a tabela

x	-1.0	-0.75	-0.6	-0.5	-0.3	0	0.2	0.4	0.5	0.7	1.0
$f(x)$	2.05	1.153	0.45	0.4	0.5	0	0.2	0.6	0.512	1.2	2.05

- O **diagrama de dispersão** desses dados tabelados sugere simetria e crescimento para $|x|$ maiores.
- É natural testar uma função-base (g_n) que tem a forma de uma parábola:

$$g_1(x) = x^2 \Rightarrow \phi(x) = \alpha x^2$$

EXEMPLO 1: TABELA E DISPERSÃO


Seja a tabela

x	-1.0	-0.75	-0.6	-0.5	-0.3	0	0.2	0.4	0.5	0.7	1.0
$f(x)$	2.05	1.153	0.45	0.4	0.5	0	0.2	0.6	0.512	1.2	2.05

- O **diagrama de dispersão** desses dados tabelados sugere simetria e crescimento para $|x|$ maiores.
- É natural testar uma função-base (g_n) que tem a forma de uma parábola:

$$g_1(x) = x^2 \Rightarrow \phi(x) = \alpha x^2$$

EXEMPLO 1: GRÁFICO DE DISPERSÃO



DA OBSERVAÇÃO AO CONCEITO DE DESVIO

Após observar o diagrama de dispersão, surge a questão:

PERGUNTA

Qual parábola $\phi(x) = \alpha x^2$, ajusta-se melhor aos dados tabelados?

DA OBSERVAÇÃO AO CONCEITO DE DESVIO

No caso geral, escolhidas as funções base $g_1(x), g_2(x), \dots, g_n(x)$, queremos determinar os coeficientes

$$\alpha_1, \alpha_2, \dots, \alpha_n$$

de modo que a função

$$\phi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x)$$

se aproxime o máximo possível da função $f(x)$ definida pelos dados tabelados.

DA OBSERVAÇÃO AO CONCEITO DE DESVIO

Que métrica podemos usar para medir o quanto $\phi(x)$ se aproxima de $f(x)$?

DESVIO

Para cada ponto tabelado ($i = 1, 2, \dots, m$), definimos o **desvio** como:

$$d_i = f(x_i) - \phi(x_i),$$

queremos que esses desvios sejam os menores possíveis.

DA OBSERVAÇÃO AO CONCEITO DE DESVIO

Que métrica podemos usar para medir o quanto $\phi(x)$ se aproxima de $f(x)$?


DESVIO

Para cada ponto tabelado ($i = 1, 2, \dots, m$), definimos o **desvio** como:

$$d_i = f(x_i) - \phi(x_i),$$

queremos que esses desvios sejam os menores possíveis.

DA OBSERVAÇÃO AO CONCEITO DE DESVIO



COMO PODEMOS ENCONTRAR OS DESVIOS MÍNIMOS?

Uma ideia natural seria calcular:

$$S = \sum_{i=1}^m f(x_i) - \phi(x_i)$$

Problema

Essa soma pode dar zero ($S = 0$) mesmo com erros grandes, pois os sinais positivos e negativos podem se cancelar.

COMO PODEMOS ENCONTRAR OS DESVIOS MÍNIMOS?


Uma ideia natural seria calcular:

$$S = \sum_{i=1}^m f(x_i) - \phi(x_i)$$


Problema

Essa soma pode dar zero ($S = 0$) mesmo com erros grandes, pois os sinais positivos e negativos podem se cancelar.

COMO PODEMOS ENCONTRAR OS DESVIOS MÍNIMOS?



$$\begin{aligned} d_1 &= d_2 = 0 \\ \Rightarrow S_1 &= d_1 + d_2 = 0 + 0 = 0 \end{aligned}$$



$$\begin{aligned} d_2 &= -d_1 \\ \Rightarrow S_2 &= d_1 + d_2 = d_1 + (-d_1) = 0 \end{aligned}$$

COMO PODEMOS ENCONTRAR OS DESVIOS MÍNIMOS?

Uma forma de resolver esse problema seria pensar em utilizar a **somas dos módulos dos desvios**, pois garante a soma de valores positivos:

$$S = \sum_{i=1}^m |f(x_i) - \phi(x_i)|$$

Problema

A função módulo é não diferenciável em zero. Desse modo, a função não é suave e não podemos utilizar derivadas parciais para calcular pontos de mínimo.

COMO PODEMOS ENCONTRAR OS DESVIOS MÍNIMOS?


Uma forma de resolver esse problema seria pensar em utilizar a **somas dos módulos dos desvios**, pois garante a soma de valores positivos:

$$S = \sum_{i=1}^m |f(x_i) - \phi(x_i)|$$

Problema


A função módulo é não diferenciável em zero. Desse modo, a função não é suave e não podemos utilizar derivadas parciais para calcular pontos de mínimo.

COMO PODEMOS ENCONTRAR OS DESVIOS MÍNIMOS?



$$|d_1| = |d_2| = 0$$

$$\Rightarrow S_1 = |d_1| + |d_2| = 0 + 0 = 0$$



$$d_2 = -d_1 \Rightarrow |d_2| = |d_1|$$

$$\Rightarrow S_2 = |d_1| + |d_2| = 2|d_1| \neq 0$$

COMO PODEMOS ENCONTRAR OS DESVIOS MÍNIMOS?

Solução

A solução seria utilizar a soma dos quadrados dos desvios, uma vez que é sempre positiva e suave (diferenciável), isto é, nos permite **encontrar o mínimo por cálculo diferencial**.

$$S = \sum_{i=1}^m [f(x_i) - \phi(x_i)]^2$$

MÉTODO DOS MÍNIMOS QUADRADOS

O método dos **Mínimos Quadrados** busca os coeficientes $\alpha_1, \alpha_2, \dots, \alpha_n$ que minimizam:

$$S(\alpha_1, \dots, \alpha_n) = \sum_{i=1}^m [f(x_i) - \phi(x_i)]^2 \Rightarrow$$

$$\Rightarrow S(\alpha_1, \dots, \alpha_n) = \sum_{i=1}^m [f(x_i) - \alpha_1 g_1(x) - \alpha_2 g_2(x) - \dots - \alpha_n g_n(x)]^2$$

De outra forma, determinar os coeficientes $\alpha_1, \alpha_2, \dots, \alpha_n$ que tornam

$$\phi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x)$$

a melhor aproximação possível de $f(x)$.

MÉTODO DOS MÍNIMOS QUADRADOS

O método dos **Mínimos Quadrados** busca os coeficientes $\alpha_1, \alpha_2, \dots, \alpha_n$ que minimizam:

$$S(\alpha_1, \dots, \alpha_n) = \sum_{i=1}^m [f(x_i) - \phi(x_i)]^2 \Rightarrow$$

$$\Rightarrow S(\alpha_1, \dots, \alpha_n) = \sum_{i=1}^m [f(x_i) - \alpha_1 g_1(x) - \alpha_2 g_2(x) - \dots - \alpha_n g_n(x)]^2$$

De outra forma, determinar os coeficientes $\alpha_1, \alpha_2, \dots, \alpha_n$ que tornam

$$\phi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x)$$

a melhor aproximação possível de $f(x)$.

MÉTODO DOS MÍNIMOS QUADRADOS

O método dos **Mínimos Quadrados** busca os coeficientes $\alpha_1, \alpha_2, \dots, \alpha_n$ que minimizam:

$$S(\alpha_1, \dots, \alpha_n) = \sum_{i=1}^m [f(x_i) - \phi(x_i)]^2 \Rightarrow$$

$$\Rightarrow S(\alpha_1, \dots, \alpha_n) = \sum_{i=1}^m [f(x_i) - \alpha_1 g_1(x) - \alpha_2 g_2(x) - \dots - \alpha_n g_n(x)]^2$$

De outra forma, determinar os coeficientes $\alpha_1, \alpha_2, \dots, \alpha_n$ que tornam

$$\phi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x)$$

a melhor aproximação possível de $f(x)$.

MÍNIMOS QUADRADOS: PONTO CRÍTICO E CONDIÇÃO DE MÍNIMO

Definição: Um ponto $(\alpha_1^*, \alpha_2^*, \dots, \alpha_n^*)$ é um **ponto crítico** de S se todas as suas derivadas parciais se anulam:

$$\frac{\partial S}{\partial \alpha_j}(\alpha_1^*, \alpha_2^*, \dots, \alpha_n^*) = 0, \quad j = 1, 2, \dots, n.$$

Ideia: Encontramos os pontos onde S é estacionária, isto é, onde a variação em qualquer direção (em relação a α_j) é nula.

OBJETIVO

Encontrar os α_j que tornam S mínima. Por ser uma função quadrática, o ponto crítico será o **mínimo global**.

DERIVANDO A FUNÇÃO S

Para cada parâmetro α_j , temos:

$$S(\alpha_1, \dots, \alpha_n) = \sum_{i=1}^m [f(x_i) - \alpha_1 g_1(x_i) - \dots - \alpha_n g_n(x_i)]^2.$$

Calculando a derivada parcial:

$$\frac{\partial S}{\partial \alpha_j} = 2 \sum_{i=1}^m [f(x_i) - \alpha_1 g_1(x_i) - \dots - \alpha_n g_n(x_i)] [-g_j(x_i)], j = 1, 2, 3, \dots, n.$$

Simplificando o sinal:

$$\frac{\partial S}{\partial \alpha_j} = -2 \sum_{i=1}^m [f(x_i) - \phi(x_i)] g_j(x_i), j = 1, 2, 3, \dots, n.$$

O fator -2 pode ser ignorado, pois não altera o ponto em que a derivada é nula.

DERIVANDO A FUNÇÃO S

Para cada parâmetro α_j , temos:

$$S(\alpha_1, \dots, \alpha_n) = \sum_{i=1}^m [f(x_i) - \alpha_1 g_1(x_i) - \dots - \alpha_n g_n(x_i)]^2.$$

Calculando a derivada parcial:

$$\frac{\partial S}{\partial \alpha_j} = 2 \sum_{i=1}^m [f(x_i) - \alpha_1 g_1(x_i) - \dots - \alpha_n g_n(x_i)] [-g_j(x_i)], j = 1, 2, 3, \dots, n.$$

Simplificando o sinal:

$$\frac{\partial S}{\partial \alpha_j} = -2 \sum_{i=1}^m [f(x_i) - \phi(x_i)] g_j(x_i), j = 1, 2, 3, \dots, n.$$

O fator -2 pode ser ignorado, pois não altera o ponto em que a derivada é nula.

DERIVANDO A FUNÇÃO S

Para cada parâmetro α_j , temos:

$$S(\alpha_1, \dots, \alpha_n) = \sum_{i=1}^m [f(x_i) - \alpha_1 g_1(x_i) - \dots - \alpha_n g_n(x_i)]^2.$$

Calculando a derivada parcial:

$$\frac{\partial S}{\partial \alpha_j} = 2 \sum_{i=1}^m [f(x_i) - \alpha_1 g_1(x_i) - \dots - \alpha_n g_n(x_i)] [-g_j(x_i)], j = 1, 2, 3, \dots, n.$$

Simplificando o sinal:

$$\frac{\partial S}{\partial \alpha_j} = -2 \sum_{i=1}^m [f(x_i) - \phi(x_i)] g_j(x_i), j = 1, 2, 3, \dots, n.$$

O fator -2 pode ser ignorado, pois não altera o ponto em que a derivada é nula.

DERIVANDO A FUNÇÃO S

Para cada parâmetro α_j , temos:

$$S(\alpha_1, \dots, \alpha_n) = \sum_{i=1}^m [f(x_i) - \alpha_1 g_1(x_i) - \dots - \alpha_n g_n(x_i)]^2.$$

Calculando a derivada parcial:

$$\frac{\partial S}{\partial \alpha_j} = 2 \sum_{i=1}^m [f(x_i) - \alpha_1 g_1(x_i) - \dots - \alpha_n g_n(x_i)] [-g_j(x_i)], j = 1, 2, 3, \dots, n.$$

Simplificando o sinal:

$$\frac{\partial S}{\partial \alpha_j} = -2 \sum_{i=1}^m [f(x_i) - \phi(x_i)] g_j(x_i), j = 1, 2, 3, \dots, n.$$

O fator -2 pode ser ignorado, pois não altera o ponto em que a derivada é nula.

DAS CONDIÇÕES DE MÍNIMO AO SISTEMA LINEAR

Isso gera um sistema com n equações e n incógnitas:

$$\begin{cases} \sum_{i=1}^m [f(x_i) - \phi(x_i)] g_1(x_i) = 0, \\ \sum_{i=1}^m [f(x_i) - \phi(x_i)] g_2(x_i) = 0, \\ \vdots \\ \sum_{i=1}^m [f(x_i) - \phi(x_i)] g_n(x_i) = 0. \end{cases}$$

INTERPRETAÇÃO

Cada equação expressa que o vetor de desvios é **ortogonal** a cada função base $g_j(x)$.

DAS CONDIÇÕES DE MÍNIMO AO SISTEMA LINEAR

Isso gera um sistema com n equações e n incógnitas:

$$\begin{cases} \sum_{i=1}^m [f(x_i) - \phi(x_i)] g_1(x_i) = 0, \\ \sum_{i=1}^m [f(x_i) - \phi(x_i)] g_2(x_i) = 0, \\ \vdots \\ \sum_{i=1}^m [f(x_i) - \phi(x_i)] g_n(x_i) = 0. \end{cases}$$

INTERPRETAÇÃO

Cada equação expressa que o vetor de desvios é **ortogonal** a cada função base $g_j(x)$.

DAS CONDIÇÕES DE MÍNIMO AO SISTEMA LINEAR

Desenvolvendo os termos, obtemos:

$$\begin{cases} \sum_{i=1}^m g_1(x_i)g_1(x_i)\alpha_1 + \cdots + \sum_{i=1}^m g_n(x_i)g_1(x_i)\alpha_n = \sum_{i=1}^m f(x_i)g_1(x_i), \\ \sum_{i=1}^m g_1(x_i)g_2(x_i)\alpha_1 + \cdots + \sum_{i=1}^m g_n(x_i)g_2(x_i)\alpha_n = \sum_{i=1}^m f(x_i)g_2(x_i), \\ \vdots \\ \sum_{i=1}^m g_1(x_i)g_n(x_i)\alpha_1 + \cdots + \sum_{i=1}^m g_n(x_i)g_n(x_i)\alpha_n = \sum_{i=1}^m f(x_i)g_n(x_i). \end{cases}$$

SISTEMA LINEAR DAS EQUAÇÕES NORMAIS

Esse sistema contém n equações e n incógnitas $\alpha_1, \alpha_2, \dots, \alpha_n$.

DAS CONDIÇÕES DE MÍNIMO AO SISTEMA LINEAR

Desenvolvendo os termos, obtemos:

$$\begin{cases} \sum_{i=1}^m g_1(x_i)g_1(x_i)\alpha_1 + \cdots + \sum_{i=1}^m g_n(x_i)g_1(x_i)\alpha_n = \sum_{i=1}^m f(x_i)g_1(x_i), \\ \sum_{i=1}^m g_1(x_i)g_2(x_i)\alpha_1 + \cdots + \sum_{i=1}^m g_n(x_i)g_2(x_i)\alpha_n = \sum_{i=1}^m f(x_i)g_2(x_i), \\ \vdots \\ \sum_{i=1}^m g_1(x_i)g_n(x_i)\alpha_1 + \cdots + \sum_{i=1}^m g_n(x_i)g_n(x_i)\alpha_n = \sum_{i=1}^m f(x_i)g_n(x_i). \end{cases}$$

SISTEMA LINEAR DAS EQUAÇÕES NORMAIS

Esse sistema contém n equações e n incógnitas $\alpha_1, \alpha_2, \dots, \alpha_n$.

FORMA MATRICIAL DOS SISTEMAS LINEARES

O sistema pode ser escrito como:

$$\boxed{A\alpha = \mathbf{b}},$$

onde:

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}, \quad \alpha = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

Com:

$$a_{ij} = \sum_{i=1}^m g_i(x_i)g_j(x_i), \quad b_i = \sum_{i=1}^m f(x_i)g_i(x_i).$$

FORMA MATRICIAL DOS SISTEMAS LINEARES

O sistema pode ser escrito como:

$$\boxed{A\alpha = \mathbf{b}},$$

onde:

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}, \quad \alpha = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

Com:

$$a_{ij} = \sum_{i=1}^m g_i(x_i)g_j(x_i), \quad b_i = \sum_{i=1}^m f(x_i)g_i(x_i).$$

FORMA MATRICIAL DOS SISTEMAS LINEARES

O sistema pode ser escrito como:

$$\boxed{A\alpha = \mathbf{b}},$$

onde:

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}, \quad \alpha = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

Com:

$$a_{ij} = \sum_{i=1}^m g_i(x_i)g_j(x_i), \quad b_i = \sum_{i=1}^m f(x_i)g_i(x_i).$$

FORMA MATRICIAL DO SISTEMA LINEAR

O sistema pode ser escrito como:

$$A\alpha = \mathbf{b},$$

onde:

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}, \quad \alpha = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

PROPRIEDADES IMPORTANTES

- Se as funções $g_j(x)$ forem linearmente independentes, então o $\det(A) \neq 0$
 - $\Rightarrow$ O sistema tem solução única
- A é **simétrica** ($a_{ij} = a_{ji}$);

PROPRIEDADES DO SISTEMA LINEAR

O sistema linear obtido das condições de mínimo é dado por:

$$A\alpha = \mathbf{b}, \quad A = \begin{bmatrix} \sum g_1 g_1 & \sum g_2 g_1 & \cdots & \sum g_n g_1 \\ \sum g_1 g_2 & \sum g_2 g_2 & \cdots & \sum g_n g_2 \\ \vdots & \vdots & \ddots & \vdots \\ \sum g_1 g_n & \sum g_2 g_n & \cdots & \sum g_n g_n \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} \sum f g_1 \\ \sum f g_2 \\ \vdots \\ \sum f g_n \end{bmatrix}.$$

MATRIZ SIMÉTRICA

Cada elemento da matriz A é dado por:

$$a_{ij} = \sum_{i=1}^m g_j(x_i) g_i(x_i),$$

$$a_{ji} = a_{ij} \Rightarrow A = A^T.$$

PROPRIEDADES DO SISTEMA LINEAR

O sistema linear obtido das condições de mínimo é dado por:

$$A\alpha = \mathbf{b}, \quad A = \begin{bmatrix} \sum g_1 g_1 & \sum g_2 g_1 & \cdots & \sum g_n g_1 \\ \sum g_1 g_2 & \sum g_2 g_2 & \cdots & \sum g_n g_2 \\ \vdots & \vdots & \ddots & \vdots \\ \sum g_1 g_n & \sum g_2 g_n & \cdots & \sum g_n g_n \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} \sum f g_1 \\ \sum f g_2 \\ \vdots \\ \sum f g_n \end{bmatrix}.$$

MATRIZ SIMÉTRICA

Cada elemento da matriz A é dado por:

$$a_{ij} = \sum_{i=1}^m g_j(x_i) g_i(x_i),$$

$$a_{ji} = a_{ij} \Rightarrow A = A^T.$$

ROTEIRO DA AULA

- 1 MOTIVAÇÃO
- 2 MÍNIMOS QUADRADOS: CASO DISCRETO
- 3 EXEMPLO - CASO LINEAR**
- 4 EXEMPLO - PARÁBOLA
- 5 EXEMPLO - CASO NÃO LINEAR
- 6 EXERCÍCIO

EXEMPLO: AJUSTE LINEAR POR MÍNIMOS QUADRADOS

Considere a tabela de dados:

x	1.0	3.0	4.0	6.0	8.0	9.0	11.0	14.0
$f(x) = y$	1.0	2.0	4.0	4.0	5.0	7.0	8.0	9.0

(A) Ajustar, por mínimos quadrados, a reta $\phi(x) = ax + b$ aos dados.

(B) Usando a reta ajustada, estimar $f(15,5)$.

O QUE QUEREMOS MINIMIZAR?

Queremos ajustar uma reta

$$\phi(x) = ax + b$$

a um conjunto de pontos (x_i, y_i) .

O objetivo é minimizar a **soma dos quadrados dos desvios**:

$$S(a, b) = \sum_{i=1}^m (y_i - (ax_i + b))^2.$$

Buscamos os valores de a e b que tornam $S(a, b)$ o menor possível.

O QUE QUEREMOS MINIMIZAR?

Queremos ajustar uma reta

$$\phi(x) = ax + b$$

a um conjunto de pontos (x_i, y_i) .

O objetivo é minimizar a **soma dos quadrados dos desvios**:

$$S(a, b) = \sum_{i=1}^m (y_i - (ax_i + b))^2.$$

Buscamos os valores de a e b que tornam $S(a, b)$ o menor possível.

CONDIÇÕES DE MÍNIMO: DERIVADAS PARCIAIS

Para encontrar o mínimo de $S(a, b)$, anulamos suas derivadas:

$$\frac{\partial S}{\partial a} = 0, \quad \frac{\partial S}{\partial b} = 0.$$

REGRA DA CADEIA

Para um termo $(y_i - ax_i - b)^2$:

$$\frac{d}{da}(y_i - ax_i - b)^2 = 2(y_i - ax_i - b) \cdot \frac{d}{da}(y_i - ax_i - b) = 2(y_i - ax_i - b) \cdot (-x_i).$$

DERIVANDO EM RELAÇÃO A a

$$S(a, b) = \sum_{i=1}^m (y_i - ax_i - b)^2$$

$$\Rightarrow \frac{\partial S}{\partial a} = -2 \sum_{i=1}^m x_i (y_i - (ax_i + b)).$$

Igualando a zero (condição de mínimo):

$$\sum_{i=1}^m x_i (y_i - (ax_i + b)) = 0.$$

DERIVANDO EM RELAÇÃO A b

De modo análogo:

$$\frac{\partial S}{\partial b} = -2 \sum_{i=1}^m (y_i - (ax_i + b)).$$

Igualando a zero:

$$\sum_{i=1}^m (y_i - (ax_i + b)) = 0.$$

SISTEMA DE EQUAÇÕES

As duas condições de mínimo formam um sistema de equações:

$$\begin{cases} \sum_{i=1}^m x_i (y_i - (ax_i + b)) = 0, \\ \sum_{i=1}^m (y_i - (ax_i + b)) = 0. \end{cases}$$

A partir delas, obtemos o sistema linear em a e b :

$$\begin{cases} \left(\sum x_i^2 \right) a + \left(\sum x_i \right) b = \sum x_i y_i, \\ \left(\sum x_i \right) a + m b = \sum y_i. \end{cases}$$

SISTEMA DE EQUAÇÕES

As duas condições de mínimo formam um sistema de equações:

$$\begin{cases} \sum_{i=1}^m x_i (y_i - (ax_i + b)) = 0, \\ \sum_{i=1}^m (y_i - (ax_i + b)) = 0. \end{cases}$$

A partir delas, obtemos o sistema linear em a e b :

$$\begin{cases} \left(\sum x_i^2 \right) a + \left(\sum x_i \right) b = \sum x_i y_i, \\ \left(\sum x_i \right) a + m b = \sum y_i. \end{cases}$$

RESUMO: FORMA MATRICIAL DO SISTEMA DE EQUAÇÕES

Para ajustar a reta $\phi(x) = ax + b$ que melhor representa os pontos (x_i, y_i) , basta resolver o **sistema linear de mínimos quadrados**:

$$\begin{bmatrix} \sum_{i=1}^m x_i^2 & \sum_{i=1}^m x_i \\ \sum_{i=1}^m x_i & m \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^m x_i y_i \\ \sum_{i=1}^m y_i \end{bmatrix}$$

APLICANDO O RESULTADO...

A partir da tabela:

$$m = 8, \quad \sum x_i = 56, \quad \sum y_i = 40, \\ \sum x_i^2 = 524, \quad \sum x_i y_i = 364.$$

Logo, o **sistema de equações** fica:

$$\underbrace{\begin{bmatrix} \sum_{i=1}^m x_i^2 & \sum_{i=1}^m x_i \\ \sum_{i=1}^m x_i & m \end{bmatrix}}_{= \begin{bmatrix} 524 & 56 \\ 56 & 8 \end{bmatrix}} \begin{bmatrix} a \\ b \end{bmatrix} = \underbrace{\begin{bmatrix} \sum_{i=1}^m x_i y_i \\ \sum_{i=1}^m y_i \end{bmatrix}}_{= \begin{bmatrix} 364 \\ 40 \end{bmatrix}} \iff \begin{cases} 524 a + 56 b = 364, \\ 56 a + 8 b = 40. \end{cases}$$

RESOLVENDO O SISTEMA (ITEM A)

Do sistema

$$\begin{cases} 524 a + 56 b = 364, \\ 56 a + 8 b = 40. \end{cases}$$

eliminando b (ou por qualquer método de sistemas lineares), obtemos:

$$a = \frac{7}{11} = 0,63636 \dots \quad \text{e} \quad b = \frac{6}{11} = 0,54545 \dots$$

$$\boxed{\phi(x) = \frac{7}{11} x + \frac{6}{11}}$$

ESTIMATIVA PEDIDA (ITEM B)

Para $x = 15,5$:

$$\phi(15,5) = a \cdot 15,5 + b = \frac{7}{11} \cdot 15,5 + \frac{6}{11} = \frac{229}{22} \approx 10,4091.$$

$$\boxed{\phi(15,5) \approx 10,41}$$

ROTEIRO DA AULA

- 1 MOTIVAÇÃO
- 2 MÍNIMOS QUADRADOS: CASO DISCRETO
- 3 EXEMPLO - CASO LINEAR
- 4 EXEMPLO - PARÁBOLA**
- 5 EXEMPLO - CASO NÃO LINEAR
- 6 EXERCÍCIO

EXEMPLO: MÍNIMOS QUADRADOS - PARÁBOLA

Considere a tabela de dados:

x	1.0	3.0	4.0	6.0	8.0	9.0	11.0	14.0
$f(x) = y$	1.0	2.0	4.0	4.0	5.0	7.0	8.0	9.0

- (A) Ajustar, por mínimos quadrados, a parábola $\phi(x) = ax^2 + bx + c$ aos dados.
- (B) Usando a parábola ajustada, estimar $f(15,5)$.

MÍNIMOS QUADRADOS - PARÁBOLA

Queremos ajustar uma parábola

$$\phi(x) = ax^2 + bx + c$$

a um conjunto de pontos (x_i, y_i) .

O objetivo é minimizar a **soma dos quadrados dos desvios**:

$$S(a, b, c) = \sum_{i=1}^m (y_i - (ax_i^2 + bx_i + c))^2.$$

Buscamos os valores de a, b, c que tornam $S(a, b, c)$ mínimo.

MÍNIMOS QUADRADOS - PARÁBOLA

Para encontrar o mínimo de $S(a, b, c)$, anulamos as derivadas parciais:

$$\frac{\partial S}{\partial a} = 0, \quad \frac{\partial S}{\partial b} = 0, \quad \frac{\partial S}{\partial c} = 0.$$

Substituindo a expressão de $S(a, b, c)$ e derivando, obtemos:

$$\begin{cases} \sum_{i=1}^m x_i^4 a + \sum_{i=1}^m x_i^3 b + \sum_{i=1}^m x_i^2 c = \sum_{i=1}^m x_i^2 y_i, \\ \sum_{i=1}^m x_i^3 a + \sum_{i=1}^m x_i^2 b + \sum_{i=1}^m x_i c = \sum_{i=1}^m x_i y_i, \\ \sum_{i=1}^m x_i^2 a + \sum_{i=1}^m x_i b + m c = \sum_{i=1}^m y_i. \end{cases}$$

MÍNIMOS QUADRADOS - PARÁBOLA

Para encontrar o mínimo de $S(a, b, c)$, anulamos as derivadas parciais:

$$\frac{\partial S}{\partial a} = 0, \quad \frac{\partial S}{\partial b} = 0, \quad \frac{\partial S}{\partial c} = 0.$$

Substituindo a expressão de $S(a, b, c)$ e derivando, obtemos:

$$\begin{cases} \sum_{i=1}^m x_i^4 a + \sum_{i=1}^m x_i^3 b + \sum_{i=1}^m x_i^2 c = \sum_{i=1}^m x_i^2 y_i, \\ \sum_{i=1}^m x_i^3 a + \sum_{i=1}^m x_i^2 b + \sum_{i=1}^m x_i c = \sum_{i=1}^m x_i y_i, \\ \sum_{i=1}^m x_i^2 a + \sum_{i=1}^m x_i b + m c = \sum_{i=1}^m y_i. \end{cases}$$

MÍNIMOS QUADRADOS - PARÁBOLA

O sistema pode ser escrito na forma matricial:

$$\begin{bmatrix} \sum_{i=1}^m x_i^4 & \sum_{i=1}^m x_i^3 & \sum_{i=1}^m x_i^2 \\ \sum_{i=1}^m x_i^3 & \sum_{i=1}^m x_i^2 & \sum_{i=1}^m x_i \\ \sum_{i=1}^m x_i^2 & \sum_{i=1}^m x_i & m \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^m x_i^2 y_i \\ \sum_{i=1}^m x_i y_i \\ \sum_{i=1}^m y_i \end{bmatrix}$$

MÍNIMOS QUADRADOS - PARÁBOLA

Resolvendo o exemplo, calculando as somas a partir dos dados tabelados, temos:

$$\begin{aligned}m &= 8, & \sum x_i &= 56, & \sum y_i &= 40, \\ \sum x_i^2 &= 524, & \sum x_i^3 &= 5624, & \sum x_i^4 &= 65348, \\ \sum x_i y_i &= 364, & \sum x_i^2 y_i &= 3846.\end{aligned}$$

MÍNIMOS QUADRADOS - PARÁBOLA (ITEM A)

O sistema linear torna-se:

$$\begin{bmatrix} 65348 & 5624 & 524 \\ 5624 & 524 & 56 \\ 524 & 56 & 8 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} 3846 \\ 364 \\ 40 \end{bmatrix}$$

Resolvendo (por eliminação de Gauss, por exemplo), obtemos:

$$a \approx -0,0092, \quad b \approx 0,7723, \quad c \approx 0,1948.$$

$$\phi(x) = -0,0092x^2 + 0,7723x + 0,1948$$

MÍNIMOS QUADRADOS - PARÁBOLA (ITEM A)

O sistema linear torna-se:

$$\begin{bmatrix} 65348 & 5624 & 524 \\ 5624 & 524 & 56 \\ 524 & 56 & 8 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} 3846 \\ 364 \\ 40 \end{bmatrix}$$

Resolvendo (por eliminação de Gauss, por exemplo), obtemos:

$$a \approx -0,0092, \quad b \approx 0,7723, \quad c \approx 0,1948.$$

$$\phi(x) = -0,0092x^2 + 0,7723x + 0,1948$$

MÍNIMOS QUADRADOS - PARÁBOLA (ITEM B)

Para estimar $f(15,5)$:

$$\begin{aligned}\phi(15,5) &= -0,0092(15,5)^2 + 0,7723(15,5) + 0,1948, \\ &\approx 9,9552.\end{aligned}$$

$$f(15,5) \approx 9,96$$

COMPARAÇÃO

Ajuste linear: $\phi(x) = \frac{7}{11}x + \frac{6}{11} \Rightarrow f(15,5) \approx 10,41$.

Ajuste parabólico: $\phi(x) = -0,0092x^2 + 0,7723x + 0,1948 \Rightarrow f(15,5) \approx 9,96$.

ROTEIRO DA AULA

- 1 MOTIVAÇÃO
- 2 MÍNIMOS QUADRADOS: CASO DISCRETO
- 3 EXEMPLO - CASO LINEAR
- 4 EXEMPLO - PARÁBOLA
- 5 EXEMPLO - CASO NÃO LINEAR**
- 6 EXERCÍCIO

CASO NÃO LINEAR

Em alguns casos, a família de funções escolhidas pode ser **não linear nos parâmetros**. Por exemplo, se o diagrama de dispersão de uma determinada função sugere um ajuste exponencial do tipo:

$$f(x) \approx \phi(x) = \alpha_1 e^{-\alpha_2 x}, \quad \alpha_1, \alpha_2 > 0.$$

Para se aplicar o método dos mínimos quadrados, é necessário realizar uma **linearização do problema** por meio de uma transformação conveniente.

Exemplo:

$$y = \alpha_1 e^{-\alpha_2 x} \quad \Rightarrow \quad z = \ln(y) \approx \ln(\alpha_1) - \alpha_2 x.$$

Definindo $a_1 = \ln(\alpha_1)$ e $a_2 = -\alpha_2$, obtemos:

$$\ln(y) \approx a_1 - a_2 x = \phi(x),$$

que é um **problema linear nos parâmetros** a_1 e a_2 .

CASO NÃO LINEAR

Em alguns casos, a família de funções escolhidas pode ser **não linear nos parâmetros**. Por exemplo, se o diagrama de dispersão de uma determinada função sugere um ajuste exponencial do tipo:

$$f(x) \approx \phi(x) = \alpha_1 e^{-\alpha_2 x}, \quad \alpha_1, \alpha_2 > 0.$$

Para se aplicar o método dos mínimos quadrados, é necessário realizar uma **linearização do problema** por meio de uma transformação conveniente.

Exemplo:

$$y = \alpha_1 e^{-\alpha_2 x} \quad \Rightarrow \quad z = \ln(y) \approx \ln(\alpha_1) - \alpha_2 x.$$

Definindo $a_1 = \ln(\alpha_1)$ e $a_2 = -\alpha_2$, obtemos:

$$\ln(y) \approx a_1 - a_2 x = \phi(x),$$

que é um **problema linear nos parâmetros** a_1 e a_2 .

CASO NÃO LINEAR

Em alguns casos, a família de funções escolhidas pode ser **não linear nos parâmetros**. Por exemplo, se o diagrama de dispersão de uma determinada função sugere um ajuste exponencial do tipo:

$$f(x) \approx \phi(x) = \alpha_1 e^{-\alpha_2 x}, \quad \alpha_1, \alpha_2 > 0.$$

Para se aplicar o método dos mínimos quadrados, é necessário realizar uma **linearização do problema** por meio de uma transformação conveniente.

Exemplo:

$$y = \alpha_1 e^{-\alpha_2 x} \quad \Rightarrow \quad z = \ln(y) \approx \ln(\alpha_1) - \alpha_2 x.$$

Definindo $a_1 = \ln(\alpha_1)$ e $a_2 = -\alpha_2$, obtemos:

$$\ln(y) \approx a_1 - a_2 x = \phi(x),$$

que é um **problema linear nos parâmetros** a_1 e a_2 .

LINEARIZAÇÃO DO PROBLEMA

O método dos mínimos quadrados pode então ser aplicado à resolução do problema **linearizado**.

Após determinar os parâmetros a_1 e a_2 , podemos calcular os parâmetros originais:

$$\alpha_1 = e^{a_1}, \quad \alpha_2 = -a_2.$$

Importante: os parâmetros assim obtidos **não são ótimos** no sentido do critério dos mínimos quadrados aplicado à função original $f(x)$, pois ajustamos o **problema linearizado** e não o problema original.

LINEARIZAÇÃO DO PROBLEMA

O método dos mínimos quadrados pode então ser aplicado à resolução do problema **linearizado**.

Após determinar os parâmetros a_1 e a_2 , podemos calcular os parâmetros originais:

$$\alpha_1 = e^{a_1}, \quad \alpha_2 = -a_2.$$


Importante: os parâmetros assim obtidos **não são ótimos** no sentido do critério dos mínimos quadrados aplicado à função original $f(x)$, pois ajustamos o **problema linearizado** e não o problema original.

EXEMPLO: MÍNIMOS QUADRADOS - CASO NÃO-LINEAR EXPONENCIAL

Considere a tabela de dados:

x	-1.0	-0.7	-0.4	-0.1	0.2	0.5	0.8	1.0
$f(x) = y$	36.547	17.264	8.155	3.852	1.820	0.860	0.406	0.246

- (A) Ajustar, por mínimos quadrados, a função $\phi(x) = \alpha_1 e^{-\alpha_2 x}$, $\alpha_1, \alpha_2 > 0$, aos dados.
- (B) Usando a reta ajustada, estimar $f(1,50)$.



EXEMPLO: MÍNIMOS QUADRADOS - CASO NÃO-LINEAR EXPONENCIAL

Conforme vimos anteriormente, a “linearização” a ser feita é:

$$z = \ln(y) \approx \ln(\alpha_1 e^{-\alpha_2 x}) = \ln(\alpha_1) - \alpha_2 x = \phi(x).$$

Assim, em vez de ajustarmos y por mínimos quadrados, ajustaremos $z = \ln(y)$ por mínimos quadrados, encontrando:

$$\phi(x) = a_1 x + a_2,$$

onde:

$$a_1 = \ln(\alpha_1), \quad a_2 = -\alpha_2.$$

(Aqui, as funções base são $g_1(x) = 1$ e $g_2(x) = x$.)

EXEMPLO: MÍNIMOS QUADRADOS - CASO NÃO-LINEAR EXPONENCIAL

Conforme vimos anteriormente, a “linearização” a ser feita é:

$$z = \ln(y) \approx \ln(\alpha_1 e^{-\alpha_2 x}) = \ln(\alpha_1) - \alpha_2 x = \phi(x).$$

Assim, em vez de ajustarmos y por mínimos quadrados, ajustaremos $z = \ln(y)$ por mínimos quadrados, encontrando:

$$\phi(x) = a_1 x + a_2,$$

onde:

$$a_1 = \ln(\alpha_1), \quad a_2 = -\alpha_2.$$

(Aqui, as funções base são $g_1(x) = 1$ e $g_2(x) = x$.)

EXEMPLO: MÍNIMOS QUADRADOS - CASO NÃO-LINEAR EXPONENCIAL

Conforme vimos anteriormente, a “linearização” a ser feita é:

$$z = \ln(y) \approx \ln(\alpha_1 e^{-\alpha_2 x}) = \ln(\alpha_1) - \alpha_2 x = \phi(x).$$

Assim, em vez de ajustarmos y por mínimos quadrados, ajustaremos $z = \ln(y)$ por mínimos quadrados, encontrando:

$$\phi(x) = a_1 x + a_2,$$

onde:

$$a_1 = \ln(\alpha_1), \quad a_2 = -\alpha_2.$$

(Aqui, as funções base são $g_1(x) = 1$ e $g_2(x) = x$.)

EXEMPLO: MÍNIMOS QUADRADOS - CASO NÃO-LINEAR EXPONENCIAL

x	-1.0	-0.7	-0.4	-0.1	0.2	0.5	0.8	1.0
$z = \ln(y)$	3.599	2.849	2.099	1.349	0.599	-0.151	-0.901	-1.402

Para ajustar a reta $\phi(x) = a_1x + a_2$ que melhor representa os pontos (x_i, y_i) , basta resolver o **sistema linear de mínimos quadrados**:

$$\begin{bmatrix} \sum_{i=1}^m x_i^2 & \sum_{i=1}^m x_i \\ \sum_{i=1}^m x_i & m \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^m x_i z_i \\ \sum_{i=1}^m z_i \end{bmatrix}$$

APLICANDO O RESULTADO...

A partir da tabela:

$$m = 8, \quad \sum x_i = 0.3, \quad \sum z_i = 8.041, \\ \sum x_i^2 = 3.59, \quad \sum x_i z_i = -8.646.$$

Logo, o **sistema de equações** fica:

$$\underbrace{\begin{bmatrix} \sum_{i=1}^m x_i^2 & \sum_{i=1}^m x_i \\ \sum_{i=1}^m x_i & m \end{bmatrix}}_{= \begin{bmatrix} 3.59 & 0.3 \\ 0.3 & 8 \end{bmatrix}} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = \underbrace{\begin{bmatrix} \sum_{i=1}^m x_i z_i \\ \sum_{i=1}^m z_i \end{bmatrix}}_{= \begin{bmatrix} -8.646 \\ 8.041 \end{bmatrix}} \iff \begin{cases} 3.59 a_1 + 0.3 a_2 = -8.646, \\ 0.3 a_1 + 8 a_2 = 8.041. \end{cases}$$

RESOLVENDO O SISTEMA E OBTENDO O MODELO FINAL

O sistema a resolver é:

$$\begin{cases} 3.59 a_1 + 0.3 a_2 = -8.646, \\ 0.3 a_1 + 8 a_2 = 8.041. \end{cases}$$

Resolvendo o sistema, obtemos:

$$a_1 \approx -2.50019, \quad a_2 \approx 1.09888.$$

Logo, o modelo ajustado no problema **linearizado** ($z = \ln y$) é:

$$z = a_1 x + a_2 = -2.50019 x + 1.09888.$$

Retornando aos parâmetros originais:

$$\alpha_1 = e^{a_2} = e^{1.09888} \approx 3.0008, \quad \alpha_2 = -a_1 = 2.50019.$$

Portanto, o modelo exponencial ajustado é:

$$\phi(x) = 3.001 e^{-2.5x}.$$

ROTEIRO DA AULA

- 1 MOTIVAÇÃO
- 2 MÍNIMOS QUADRADOS: CASO DISCRETO
- 3 EXEMPLO - CASO LINEAR
- 4 EXEMPLO - PARÁBOLA
- 5 EXEMPLO - CASO NÃO LINEAR
- 6 EXERCÍCIO

EXERCÍCIO 1: ENUNCIADO

Considere a tabela de dados:

x	0	2	3	5	7	9	12
$f(x) = y$	1.1	2.3	3.2	5.0	6.2	8.1	10.4

- (A) Ajustar, por mínimos quadrados, a reta $\phi(x) = ax + b$ aos dados.
- (B) Usando a reta ajustada, estimar $f(10,5)$.

EXERCÍCIO 1: SOLUÇÃO

Para $\phi(x) = ax + b$, o sistema fica:

$$\begin{bmatrix} \sum x_i^2 & \sum x_i \\ \sum x_i & m \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum x_i y_i \\ \sum y_i \end{bmatrix}.$$

A partir da tabela (com $m = 7$):

$$\sum x_i = 38, \quad \sum y_i = 36,3, \quad \sum x_i^2 = 312, \quad \sum x_i y_i = 280,3.$$

Substituindo:

$$\underbrace{\begin{bmatrix} 312 & 38 \\ 38 & 7 \end{bmatrix}}_{\sum x_i^2, \sum x_i} \begin{bmatrix} a \\ b \end{bmatrix} = \underbrace{\begin{bmatrix} 280,3 \\ 36,3 \end{bmatrix}}_{\sum x_i y_i, \sum y_i} \implies \begin{cases} 312 a + 38 b = 280,3, \\ 38 a + 7 b = 36,3. \end{cases}$$

EXERCÍCIO 1: SOLUÇÃO

(A) Resolvendo, obtemos (aprox.):

$$a \approx 0,7874, \quad b \approx 0,9111, \quad \Rightarrow \quad \boxed{\phi(x) \approx 0,7874x + 0,9111}.$$

(B) Para $x = 10,5$:

$$f(10,5) \approx \phi(10,5) = 0,7874 \cdot 10,5 + 0,9111 \approx 9,1791.$$

$$\boxed{f(10,5) \approx 9,18}$$

EXERCÍCIO 2: ENUNCIADO

Considere a tabela de dados:

x	0	2	3	5	7	9	12
$f(x) = y$	1.1	2.3	3.2	5.0	6.2	8.1	10.4

(A) Ajustar, por mínimos quadrados, a reta

$$\phi(x) = \alpha_1 + \alpha_2 \cos(\omega x), \quad \text{com } \omega = \frac{\pi}{6}.$$

aos dados, estimando α_1 e α_2 .

(B) Usando a reta ajustada, estimar $f(10,5)$.

EXERCÍCIO 1: SOLUÇÃO (A)

Defina $t_i = \cos(\omega x_i)$ com $\omega = \pi/6$. Então o modelo fica

$$y_i \approx \alpha_1 + \alpha_2 t_i,$$

linear em α_1 e α_2 .

Para os dados:

$$(t_i) = [1, 0,5, 0, -0,8660, -0,8660, 0, 1].$$

Com $m = 7$ e os somatórios:

$$\sum t_i \approx 0,7679, \quad \sum t_i^2 = 3,75, \quad \sum y_i = 36,3, \quad \sum t_i y_i \approx 2,9505.$$

As equações normais para α_1 (intercepto) e α_2 são:

$$\begin{bmatrix} m & \sum t_i \\ \sum t_i & \sum t_i^2 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum t_i y_i \end{bmatrix}.$$

EXERCÍCIO 1: SOLUÇÃO (A)

Substituindo os somatórios:

$$\underbrace{\begin{bmatrix} 7 & 0,7679 \\ 0,7679 & 3,75 \end{bmatrix}}_{m, \sum t_i, \sum t_i^2} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \underbrace{\begin{bmatrix} 36,3 \\ 2,9505 \end{bmatrix}}_{\sum y_i, \sum t_i y_i}.$$

Resolvendo:

$$\alpha_1 \approx 5,2166, \quad \alpha_2 \approx -0,2815.$$

Logo, a curva ajustada é

$$\phi(x) \approx 5,2166 - 0,2815 \cos\left(\frac{\pi}{6}x\right).$$

EXERCÍCIO 1: SOLUÇÃO (B)

$$\phi(10,5) \approx 5,2166 - 0,2815 \cos\left(\frac{\pi}{6} \cdot 10,5\right) \approx 5,0176.$$

$$f(10,5) \approx 5,02$$